Выбор тензорных представлений для прогнозирования по мультимодальным измерениям

Алсаханова Н. Ю., Стрижов В. В.
alsahanova.nyu@phystech.edu, strijov@phystech.edu

В данной работе решается задача прогнозирования по измерениям с разнородных источников путем выбора оптимального тензорного представления исходных данных. Оптимальное представление предлагается получать согласованием мультимодальных измерений. Далее строится прогностическая модель путем согласования независимых и целевой переменных.

Ключевые слова: *декодирование сигналов, электрокортикограммы, метод частичных наименьших квадратов.*

1 Введение

Исходные данные в области декодирования сигналов [1], [2], [3] являются многомерными и сильно избыточными. В следствие чего модели, построенные на таких данных, неустойчивы. Так же значительно увеличивается время вычислений. Для решения этих проблем применяют модели отбора признаков [4], [5] и снижения размерности [6].

Часто в задаче декодирования имеется несколько входных сигналов, мультимодальные измерения. Например, в задаче восстановления траектории движения руки имеется 64 входных сигнала электрокортикограмм [2]. Для решения задачи с мультимодальными измерениями применяются две различные группы подходов, описанные в [7]. Одна группа состоит из методов, переводящих мультимодальные измерения в одно низкоразмерное представление. Другая группа методов путем согласования мультимодальных измерений проектирует их в низкоразмерное пространство, сохраняя их количество. Например, применяется канонический корреляционный анализ (CCA) и некоторые его модификации [8], [9], [10]. Так же согласование мультимодальных измерений проводится путем применения метода частичных наименьших квадратов (PLS) и его разновидности [11], [12].

При прогнозировании временных рядов исходные данные имеют высокую размерность, так же в пространствах целевой и независимой переменных есть скрытые зависимости. Черезмерно высокая размерность пространств и наблюдаемая множественная корреляция приводит к неустойчивости прогностичекой модели. В данном случае регрессионная модель, основанная на методе частичных наименьших квадратов широко используется для восстановления зависимостей между наборами данных [13], [14], [15], [16]. Для построения устойчивой прогностической модели так же используют метод отбора признаков, основанный на задаче квадратичного программирования (QPFS) [3]. Данный метод максимизирует релевантность и минимизирует избыточность признаков. В статье [5] показано, что метод QPFS превосходит многие существующие методы отбора признаков для задачи одномерной регрессии.

Все вышеуказанные методы используют матричное представление данных для прогнозирования временных рядов. Но в задаче с мультимодальными измерениями данные представляются в тензорном виде. Можно решать задачу путем перехода от тензоров к матрицам, но это снижает интерпретируемость и увеличивает избыточность данных. Поэтому для работы с тензорными данными предлагались различные модели [17], [18]. Были предложены тензорные модификации ядерного метода главных компонент (tensor KPCA) [19],

канонического корреляционного анализа (tensor CCA) [20] и метода частичных наименьших квадратов (HOPLS) [21]. В статьях [22], [23] были рассмотрены нелинейные версии тензорного метода частичных наименьших квадратов.

В данной работе предлагается

2 Постановка задачи

Пусть $\mathbf{X}$ - временной ряд полученный с одного источника, $\mathbf{Y}$ - прогнозируемый временной ряд. Задача прогнозирования в этом случае будет заключаться в поиске оптимальной модели $\mathbf{F}$. Под оптимальностью понимается нахождение такой модели, которая минимизирует некоторый функционал ошибки.

$$\mathbf{F} = \arg\min_{F} \mathcal{L}\left(\mathbf{F}, \mathbf{X}, \mathbf{Y}\right) \tag{1}$$

В нотации Пенроуза данная задача будет выглядеть в виде, представленном на рис. 1.

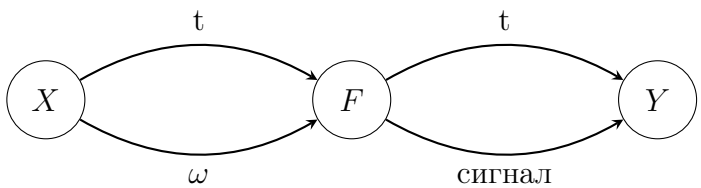

Рис. 1 Задача с одним источником

Пусть $\mathbf{X}'$ - временной ряд полученный с другого источника. При добавлении $\mathbf{X}'$ может получится один из 4 вариантов:

1) $\mathbf{X}$ и $\mathbf{X}'$ перпендикулярны друг другу;
2) $\mathbf{X}'$ приближает $\mathbf{Y}$;
3) $\mathbf{X}$ и $\mathbf{X}'$ коррелируют;
4) $\mathbf{X}'$ и $\mathbf{Y}$ перпендикулярны друг другу, тогда $\mathbf{X}'$ не несет никакой информации для предсказания $\mathbf{Y}$.

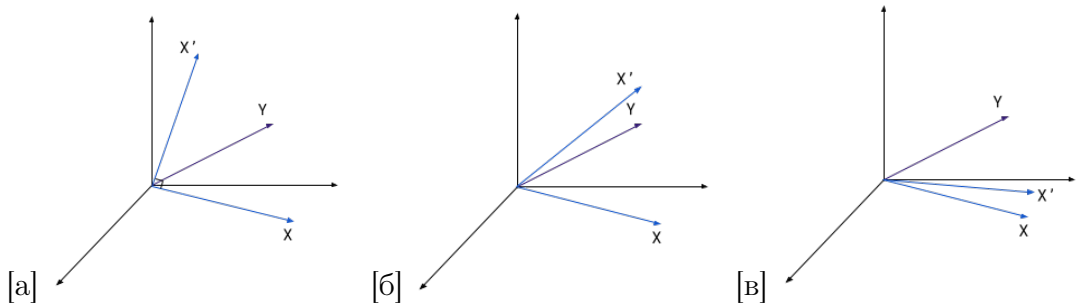

Рис. 2 (а) некоррелирующие признаки, (б) $\mathbf{X}'$ приближает $\mathbf{Y}$, (в) коррелирующие признаки

Решать задачу прогнозирования $\mathbf{Y}$ по сигналам $\mathbf{X}$ и $\mathbf{X}'$ можно путем объединения сигналов $\mathbf{X}$ и $\mathbf{X}'$ в одну матрицу $\hat{\mathbf{X}}$. И тогда задача сводится к показанной на рис 1. В данной работе предлагается проводить согласование путем ...

Литература

[1] Andrey Eliseyev, Cecile Moro, Jean Faber, Alexander Wyss, Napoleon Torres, Corinne Mestais, Alim Louis Benabid, and Tetiana Aksenova. L1-penalized n-way pls for subset of electrodes selection in bci experiments. *Journal of neural engineering*, 9(4):045010, 2012.

[2] Andrey Eliseyev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand trajectories from ecog signals using the generalized additive model. *Journal of neural engineering*, 11(6):066005, 2014.

[3] Anastasia Motrenko and Vadim V. Strijov. Multi-way feature selection for ecog-based brain-computer interface. *Expert Syst. Appl*, 114:402–413, 2018.

[4] Tahir Mehmood, Kristian Hovde Liland, Lars Snipen, and Solve Saebo. A review of variable selection methods in partial least squares regression. *Chemometrics and Intelligent Laboratory Systems*, 118:62–69, 2012.

[5] Alexandr Katrutsa and Vadim Strijov. Comprehensive study of feature selection methods to solve multicollinearity problem according to evaluation criteria. *Expert Systems with Applications*, 76:1–11, 2017.

[6] A. M. Katrutsa and V. V. Strijov. Stress test procedure for feature selection algorithms. *Chemometrics and Intelligent Laboratory Systems*, 142:172–183, 2015.

[7] Yingming Li, Ming Yang, and Zhongfei Zhang. A survey of multi-view representation learning. *IEEE Trans. Knowl. Data Eng*, 31(10):1863–1883, 2019.

[8] Adrian Benton, Huda Khayrallah, Biman Gujral, Drew Reisinger, Sheng Zhang, and Raman Arora. Deep generalized canonical correlation analysis. *CoRR*, 2017.

[9] Hok Shing Wong, Li Wang, Raymond H. Chan, and Tieyong Zeng. Deep tensor cca for multi-view learning. *CoRR*, abs/2005.11914, 2020.

[10] Heather D. Couture, Roland Kwitt, J. S. Marron, Melissa A. Troester, Charles M. Perou, and Marc Niethammer. Deep multi-view learning via task-optimal cca. *CoRR*, abs/1907.07739, 2019.

[11] Andrey Eliseyev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth trajectory decoding from electrocorticographic (ecog) recording. *PloS one*, 11(5):e0154878, 2016.

[12] Roman Rosipal. Nonlinear partial least squares an overview. In *Chemoinformatics and advanced machine learning perspectives complex computational methods and collaborative techniques*, pages 169–189. IGI Global, 2011.

[13] Roman Rosipal and Nicole Kramer. Overview and Recent Advances in Partial Least Squares. *C. Saunders et al. (Eds.) SLSFS 2005, LNCS 3940*, pages 34–51, 2006.

[14] Alexander E. Stott, Bruno Scalzo Dees, Ilia Kisil, and Danilo P. Mandic. A class of multidimensional nipals algorithms for quaternion and tensor partial least squares regression. *Signal Process*, 160:316–327, 2019.

[15] Tahir Mehmood, Solve Sæbø, and Kristian Hovde Liland. Comparison of variable selection methods in partial least squares regression. *Journal of Chemometrics*, 2020.

[16] Julien Lauzon-Gauthier, Petre Manolescu, and Carl Duchesne. The sequential multi-block pls algorithm (smb-pls): Comparison of performance and interpretability. *Chemometrics and Intelligent Laboratory Systems*, (180):72–83, 2014.

[17] Eric F. Lock. Tensor-on-tensor regression. *Journal of Computational and Graphical Statistics*, 27(3):638–647, 2018.

[18] Mostafa Reisi Gahrooei, Hao Yan, Kamran Paynabar, and Jianjun Shi. Multiple tensor-on-tensor regression: An approach for modeling processes with heterogeneous sources of data. *Technometrics*, 2020.

[19] Lynn Houthuys and Johan A. K. Suykens. Tensor learning in multi-view kernel pca. *Artificial Neural Networks and Machine Learning - ICANN 2018*, 11140:205–215, 2018.

[20] Yong Luo, Dacheng Tao, Kotagiri Ramamohanarao, Chaoc Xu, and Yonggang Wen. Tensor canonical correlation analysis for multi-view dimension reduction. *IEEE Trans. Knowl. Data Eng*, 27:3111–3124, 2015.

[21] Qibin Zhao, Cesar F. Caiafa, Danilo P. Mandic, Zenas C. Chao, Yasuo Nagasaka, Naotaka Fujii, Liqing Zhang, and Andrzej Cichocki. Higher-order partial least squares (hopls): A generalized multi-linear regression method. *Pattern Analysis and Machine Intelligence, IEEE Transactions*, 35(7), 2012.

[22] Xu X. Feng, Y. and Y. Meng. Short-term load forecasting with tensor partial least squares-neural network. *Energies*, 990(12), 2019.

[23] Zhang L. Zhao, Q. and A. Cichocki. Multilinear and nonlinear generalizations of partial least squares: an overview of recent advances. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, (4):104–115, 2014.